

KM RAG 系統設計說明

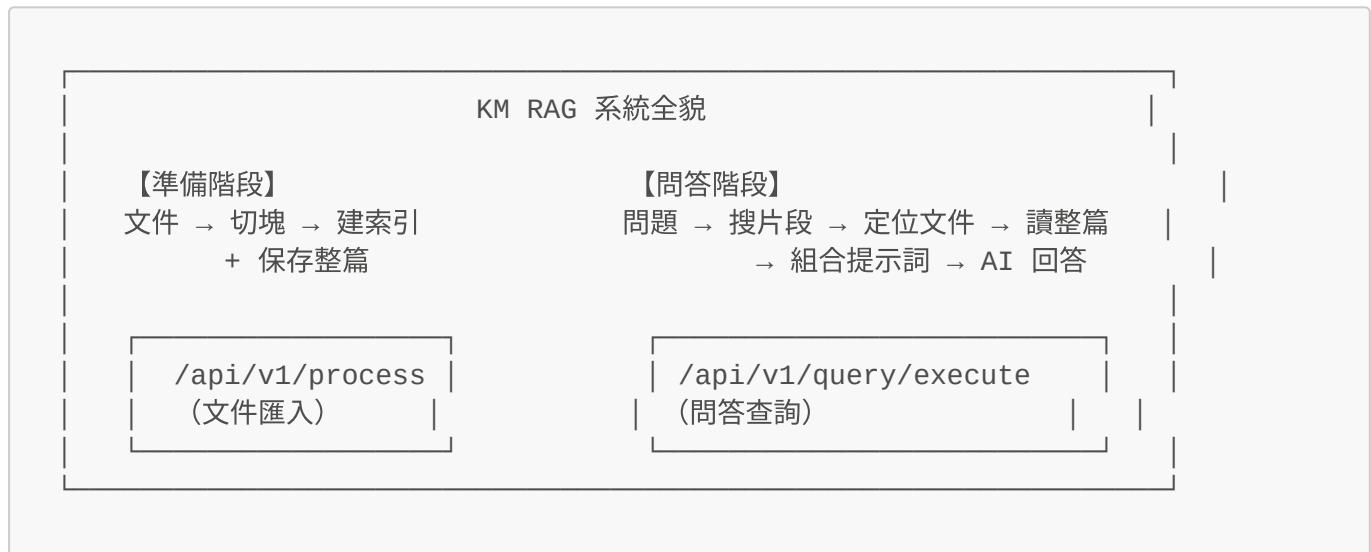
本文件以概念角度，圖解說明 [/api/v1/query/execute](#) 背後的 RAG (Retrieval-Augmented Generation，檢索增強生成) 系統如何運作。

一、什麼是 RAG？一句話解釋

先從知識庫「找資料」，再把找到的資料「餵給 AI」，讓 AI 根據這些資料回答問題。

傳統的 AI 只能靠自己訓練時學到的知識回答，容易「幻覺」(瞎編)。RAG 的核心思路是：**回答之前先查書**。

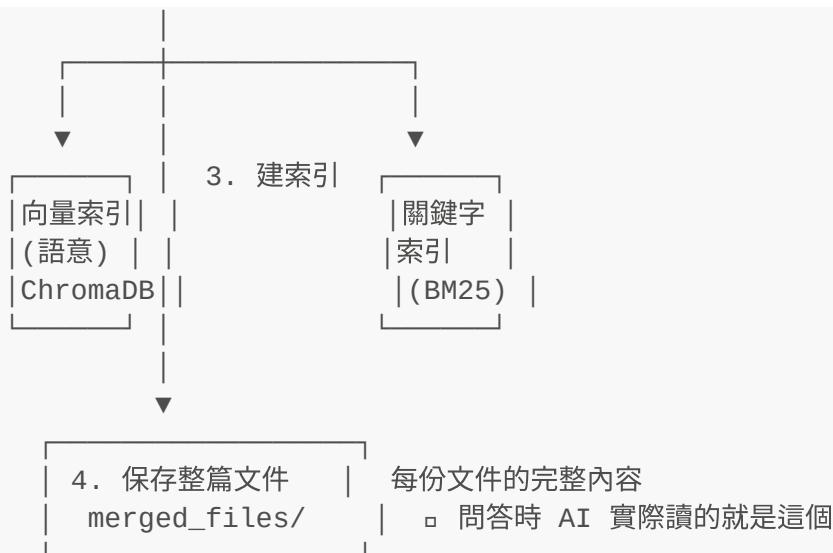
二、全局流程鳥瞰



三、準備階段：把文件變成「AI 能搜尋的知識庫」

概念流程圖





每個步驟在做什麼？

步驟	做什麼	生活比喻
文件解析	把各種格式（PDF、Word 等）轉成純文字	把手寫筆記打成電子檔
文件切塊	把整份文件切成適當大小的段落	把一本書的內容做成一張張索引卡
向量索引	用 AI 把每段文字轉成「數字向量」，理解語意	幫每張卡片標記「這張在講什麼概念」
關鍵字索引	建立傳統的關鍵字搜尋索引（BM25）	幫每張卡片標記「這張出現了哪些詞」
保存整篇文件	每份文件的完整內容存入 merged_files/	把原本的書也放在書架上，方便之後整本拿出來 給 AI 讀

對應的 API

```

POST /api/v1/process
  └─ 輸入：collection 名稱 + 檔案清單
  └─ 回傳：task_id (非同步處理)

  └─ GET /api/v1/status/{task_id} ← 查詢處理進度
      └─ 回傳：pending → processing → completed
  
```

四、問答階段：[/api/v1/query/execute](#) 的完整流程

這是測試檔案重點測試的 API，也是整個 RAG 系統的核心。

核心設計理念：「用片段找文件，用整篇餵 AI」

一般的 RAG 系統會把搜到的「片段」直接拼給 AI。但這個系統不一樣——**搜尋片段只是為了「定位是哪份文件最相關」**，定位到之後，會去讀取那份文件的**完整內容**，整篇餵給 AI。

為什麼這樣設計？因為片段可能斷章取義，把整篇文件給 AI，AI 才能理解完整脈絡。

概念流程圖

▫ 使用者提問

「員工試用期有多長？」



/api/v1/query/execute

Step 1 — 搜尋片段，定位文件 (Retrieval)

問題 → □ 搜尋引擎 (二選一)

Semantic (向量語意搜尋)
或
BM25 (關鍵字搜尋)

回傳 k 筆最相關的「片段」 (chunks)

#1	#2	#3	#4	#5
----	----	----	----	----

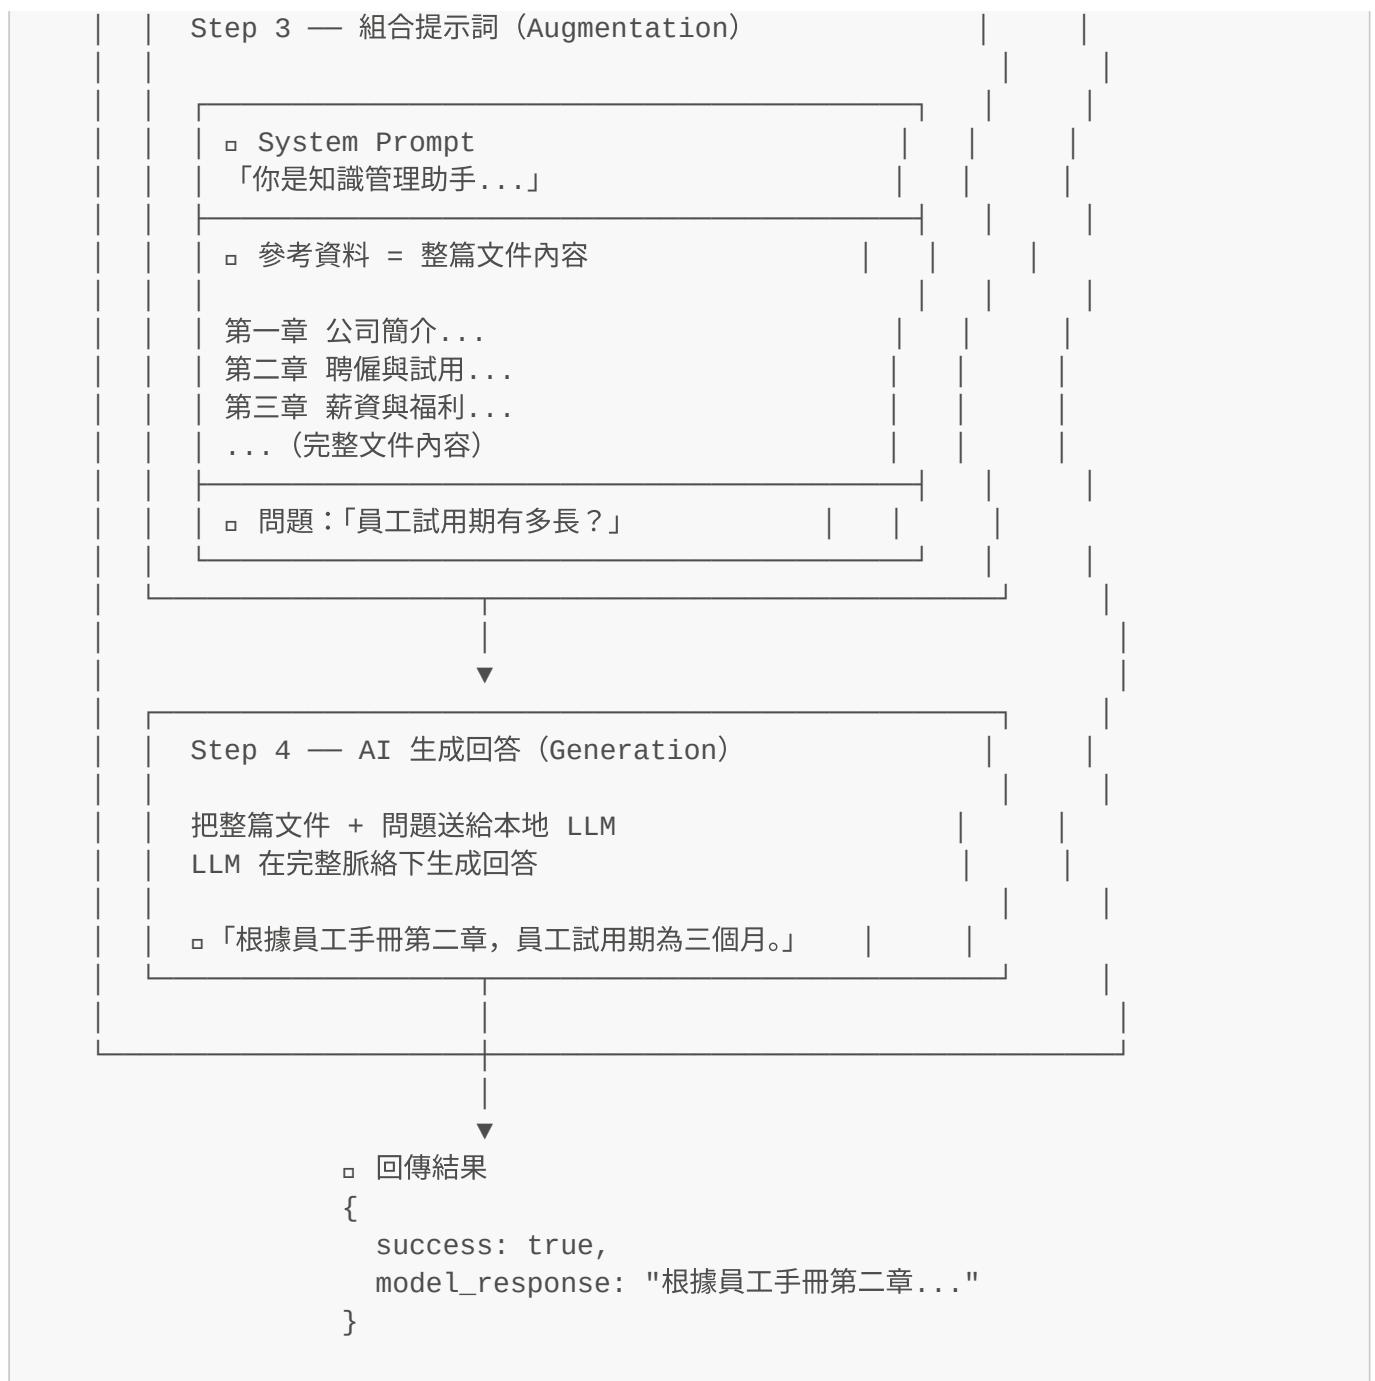
只看第 1 筆！取出它的 group_id
(group_id = 這個片段屬於哪份文件)

Step 2 — 讀取整篇原始文件

group_id: "員工手冊"

▫ merged_files/員工手冊.txt

讀取整篇文件的完整內容
(不是只拿片段，而是整份文件)



四個步驟的生活比喻

想像你是一位圖書館員，有人來問你問題：

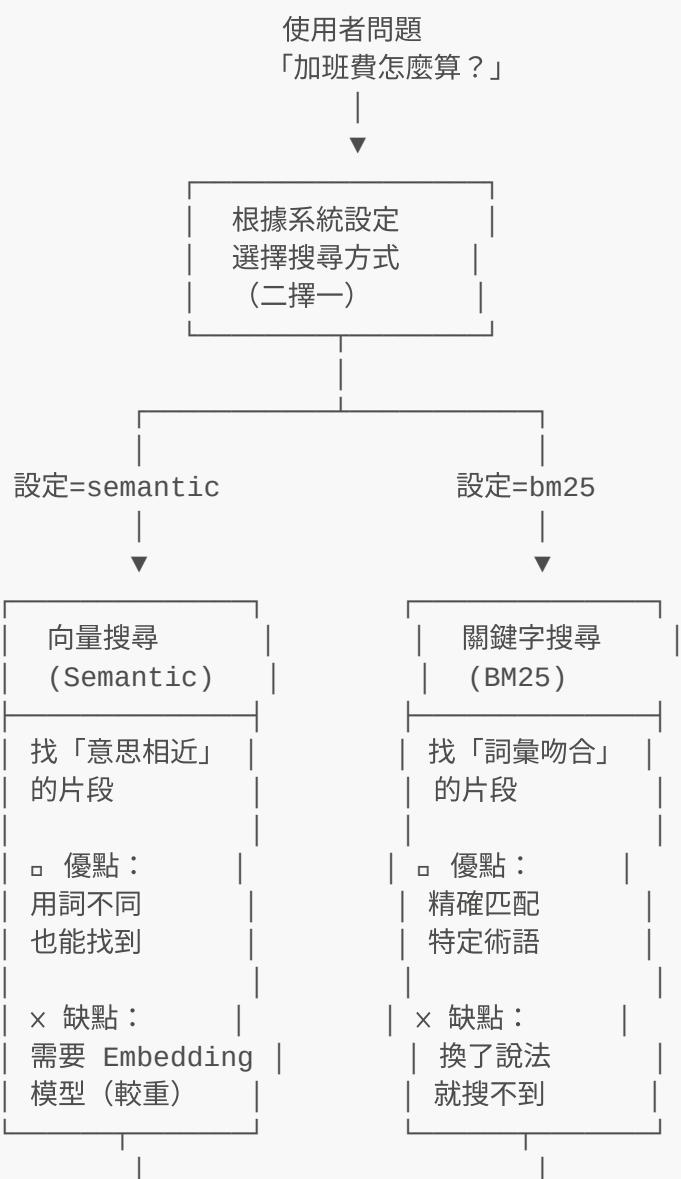
步驟	圖書館員做的事
Step 1 搜尋片段	用索引卡片搜尋，找到「員工手冊」這本書最可能有答案
Step 2 讀取整篇	不只看索引卡片，而是把整本書從書架上拿下來
Step 3 組合提示	把整本書攤開在桌上，旁邊放上問題
Step 4 AI 回答	讓 AI 讀完整本書後，回答問題

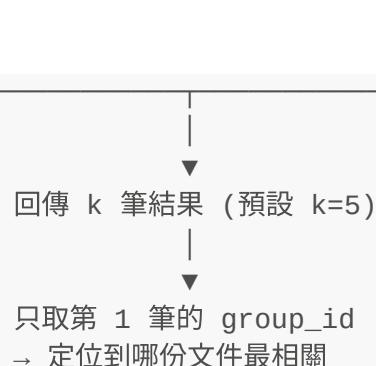
為什麼不只給片段，而要給整篇？

一般 RAG (給片段)	本系統 KM RAG (給整篇)
「...試用期為三個月...」	▫ 完整員工手冊
「...試用期滿需評核...」	(第一章到最後一章)
「...未通過可延長...」	
✗ 片段之間可能斷章取義	▫ AI 能看到完整脈絡
✗ 遺漏未被搜到的相關資訊	▫ 不會漏掉同份文件的資訊
▫ 省 token、速度快	✗ 消耗較多 token

五、搜尋引擎：二擇一機制 (Semantic 或 BM25)

系統提供兩種搜尋演算法，但每次查詢只會使用其中一種（由設定檔決定），不是兩者合併：

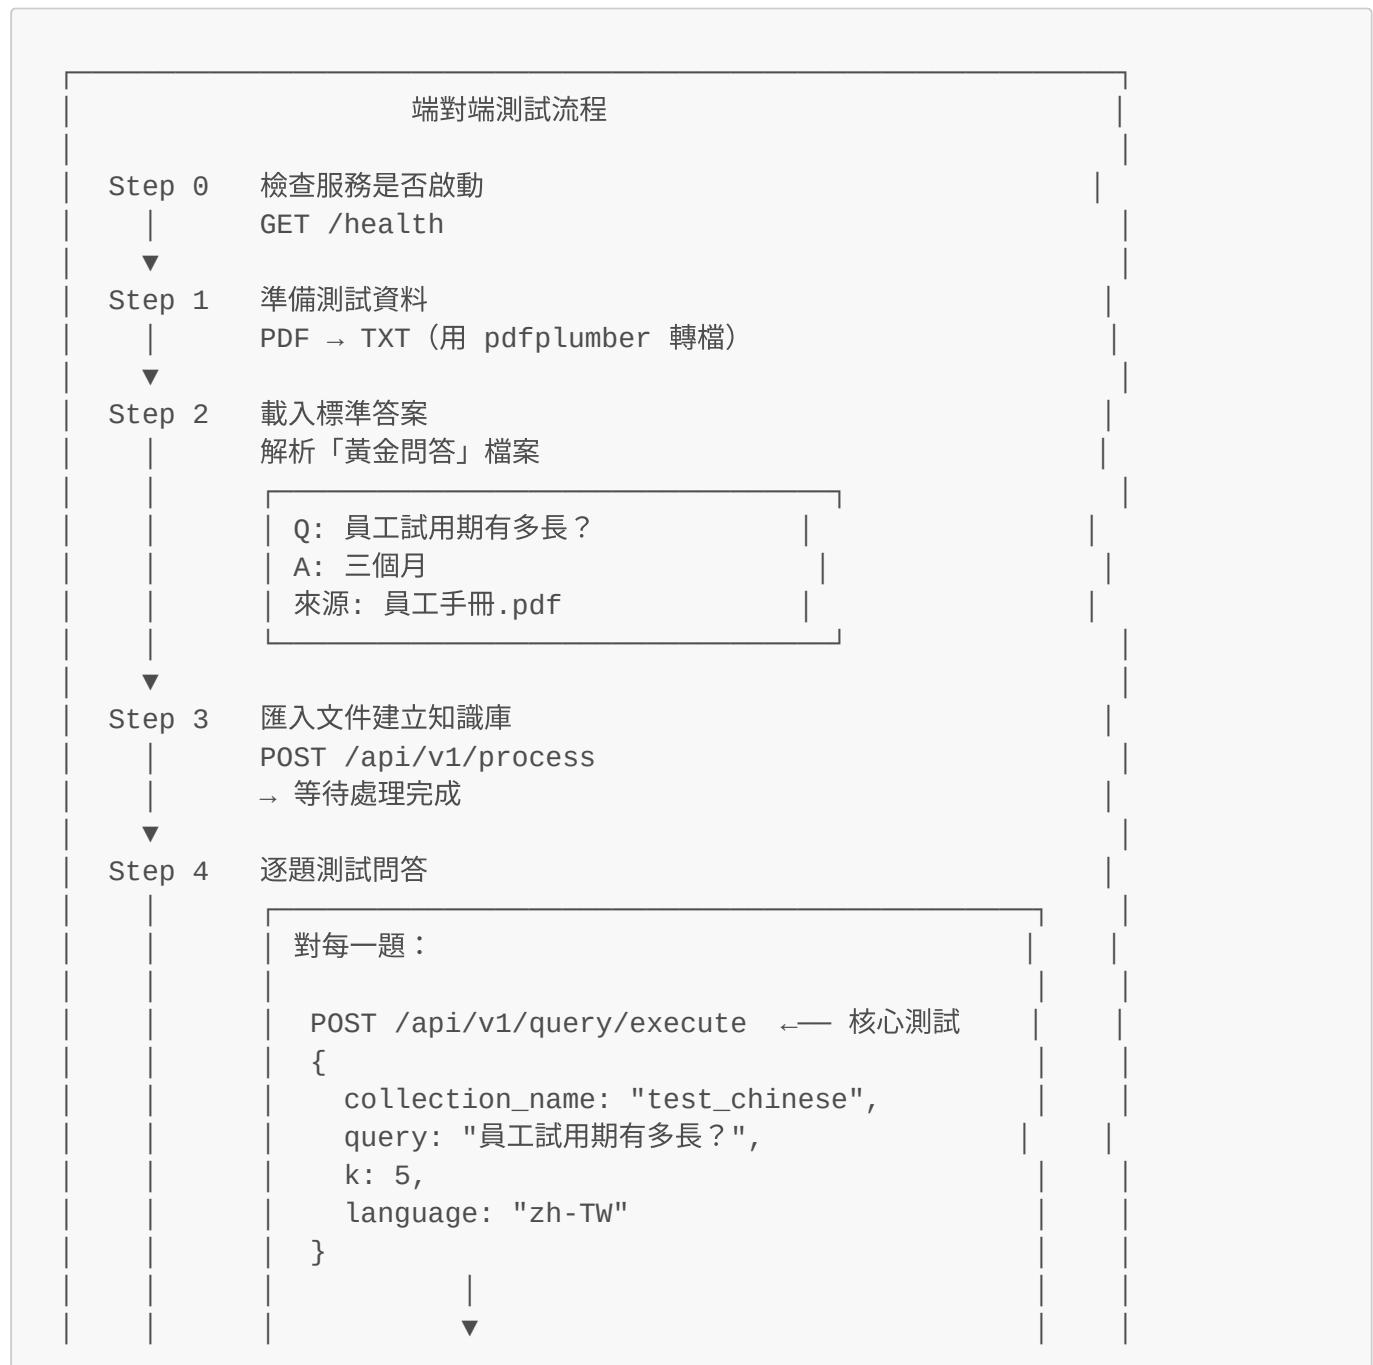


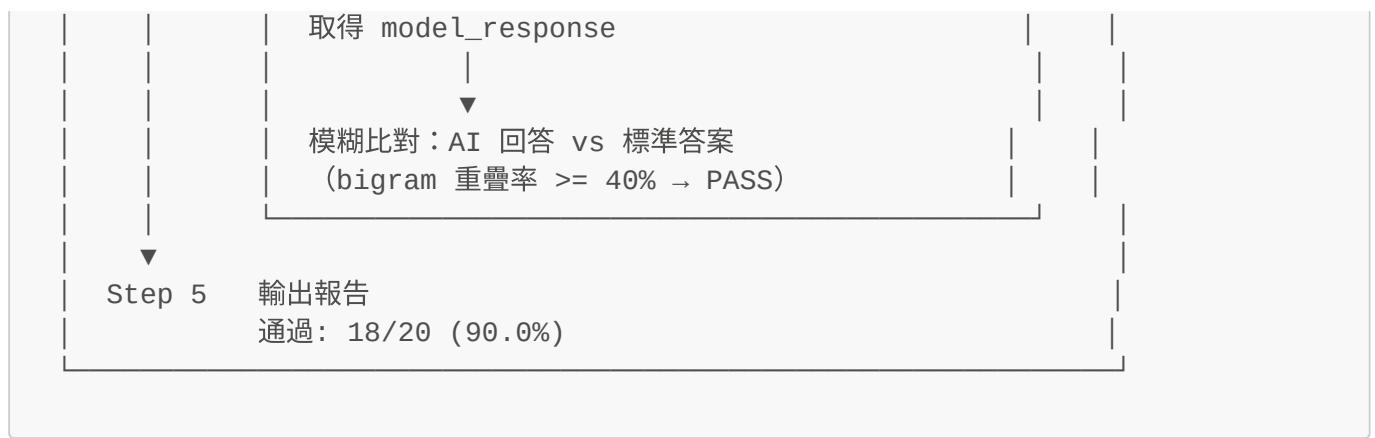


注意：搜尋回傳 k 筆片段，但系統**只關心排名第 1 的那筆**屬於哪份文件。搜尋的目的不是收集片段，而是**找出最相關的那份文件**。

六、測試怎麼驗證這個系統？

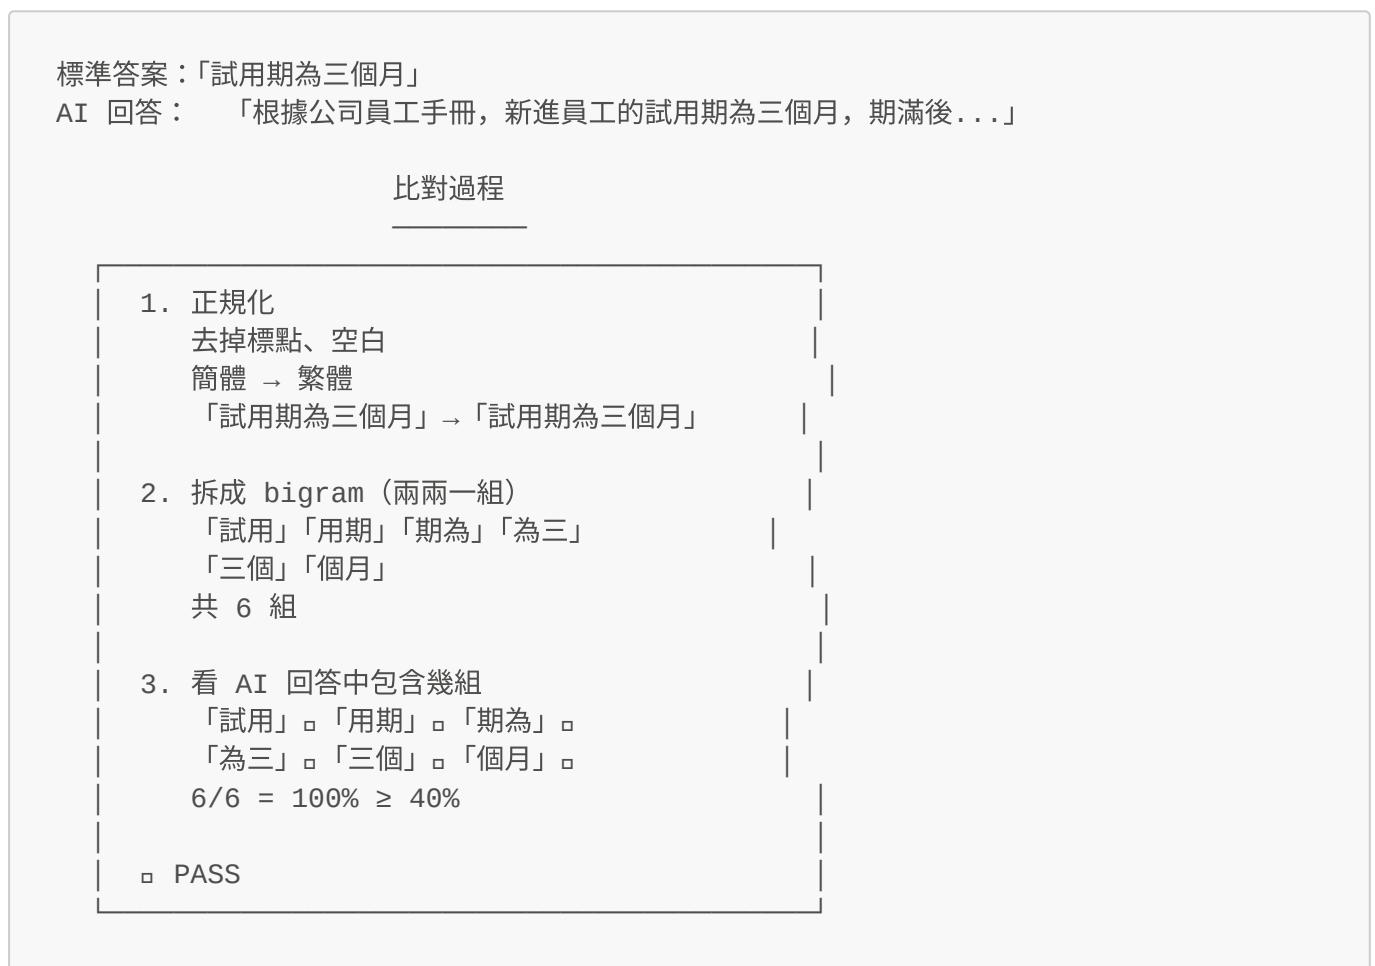
測試腳本 `test_rag.py` 用「黃金問答」（標準答案）來驗證整個流程：





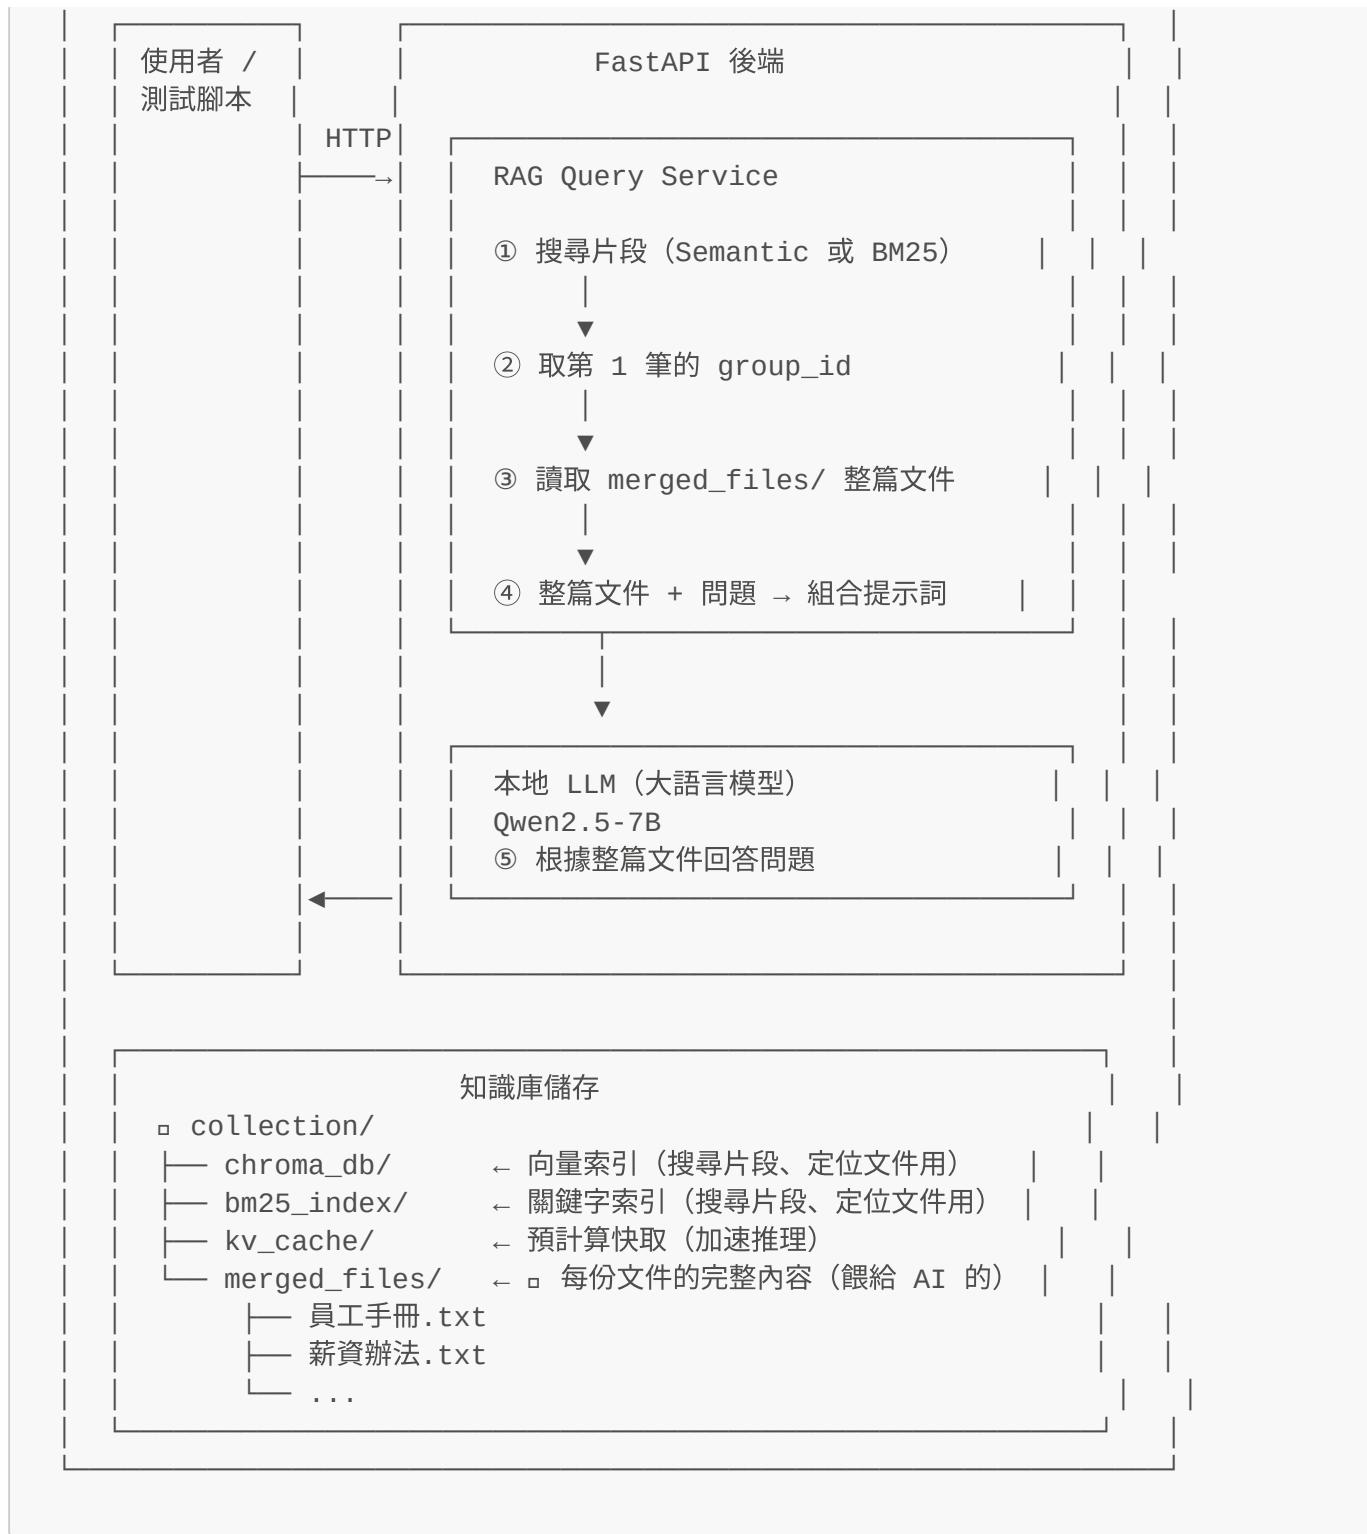
七、答案驗證機制：模糊比對

測試不是要求 AI 回答一模一樣，而是用「模糊比對」來判斷是否正確：



為什麼用模糊比對？因為 AI 的回答不會跟標準答案一字不差，只要「關鍵資訊有被提到」就算通過。40% 的門檻代表：即使 AI 用了不同的措辭，只要核心內容有覆蓋到就行。

八、系統架構總覽



九、API 互動一覽

API 端點	用途	階段
GET /health	確認服務是否存活	前置檢查
GET /api/v1/collections	列出已建立的知識庫	前置檢查
POST /api/v1/process	匯入文件、建立知識庫	準備階段
GET /api/v1/status/{task_id}	查詢文件處理進度	準備階段

API 端點	用途	階段
POST /api/v1/query/execute	RAG 問答（核心）	問答階段

十、一句話總結

`/api/v1/query/execute` 的 RAG 設計就是：收到問題 → 用搜尋引擎（Semantic 或 BM25 擇一）找出最相關的片段 → 取排名第 1 的片段定位到它所屬的原始文件 → 讀取該文件的完整內容 → 把整篇文章 + 問題組合成提示詞 → 送給本地 AI 模型生成回答。測試則透過「黃金問答 + 模糊比對」來驗證整條流水線是否正確運作。